Clustering
Métricas de clustering

Georgina Stegmayer
Inteligencia Computacional
Departamento de Informática
FICH-UNL

gstegmayer@sinc.unl.edu.ar

Aprendizaje no supervisado = clustering

Clustering

Agrupar objetos similares basados en alguna noción de similaridad. El resultado es una partición de los datos.

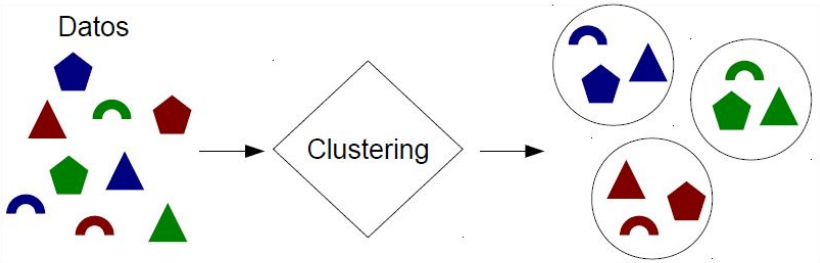
Aprendizaje no supervisado = clustering

Clustering

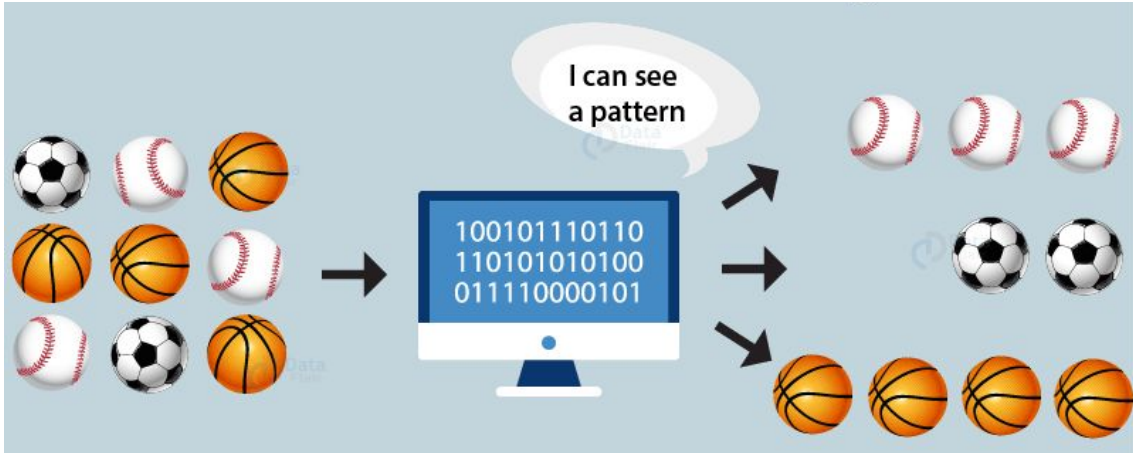
Agrupar objetos similares basados en alguna noción de similaridad. El resultado es una partición de los datos.

Cluster

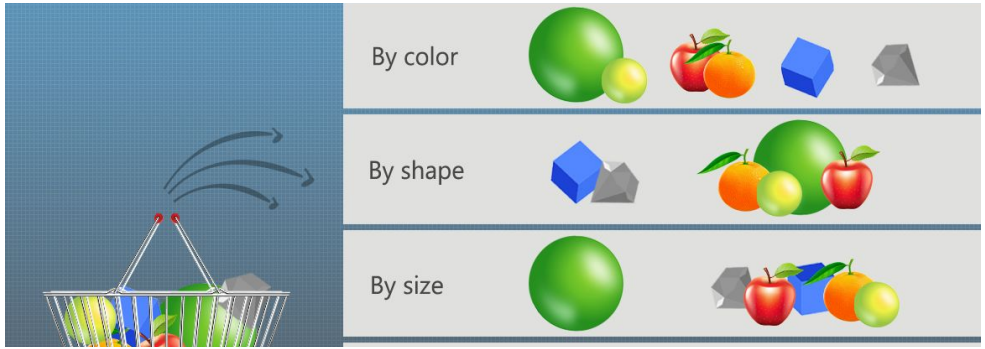
Un conjunto de objetos que son similares entre ellos, mientras que difieren de los objetos en otros clusters.



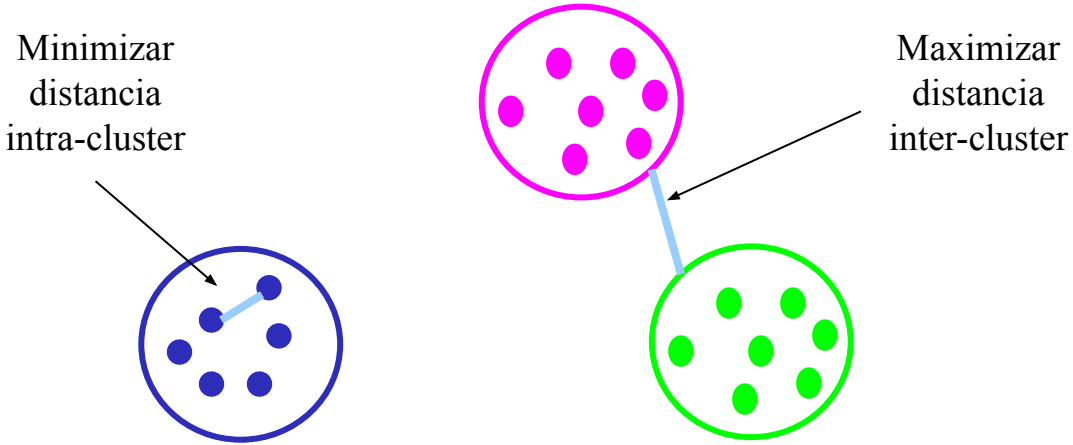
Aprendizaje no supervisado = clustering



Aprendizaje no supervisado = clustering

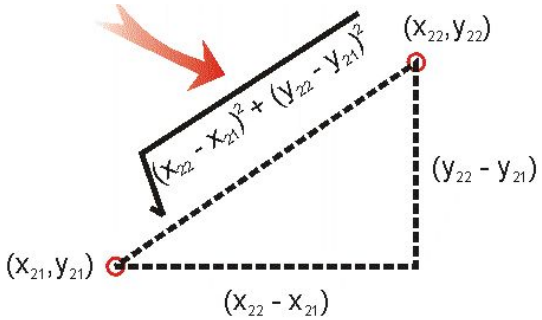


Aprendizaje no supervisado = clustering

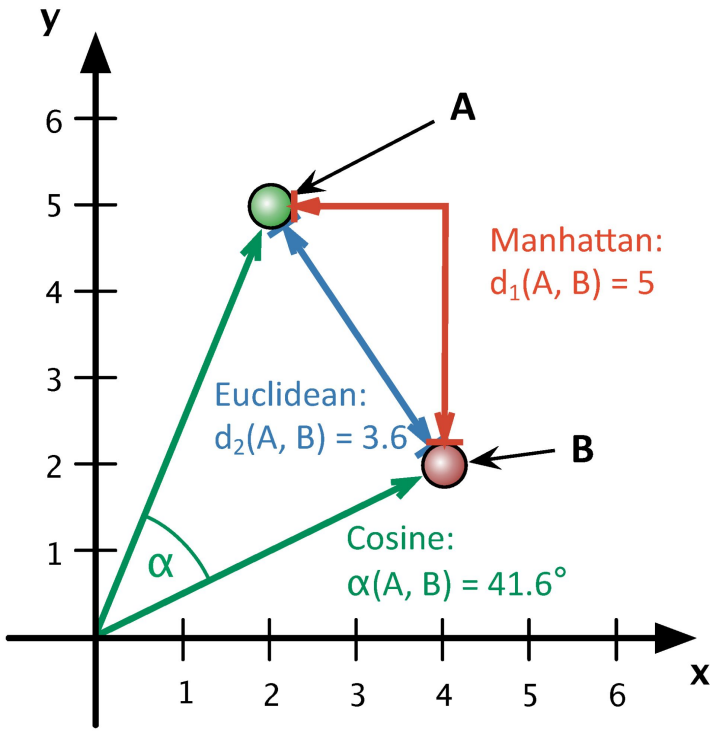


Clustering - distancia

distancia euclídea entre 2 puntos



Clustering - distancia

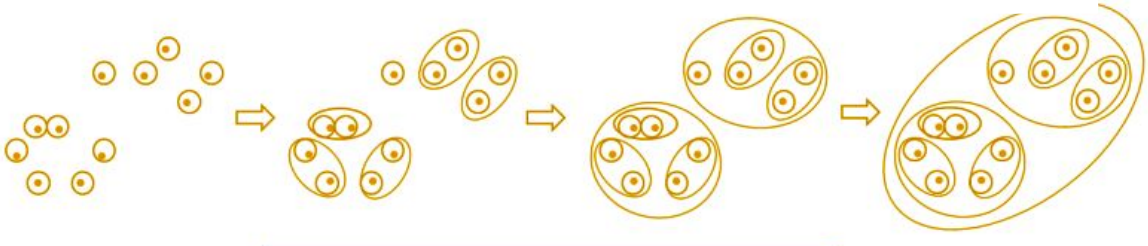


Clustering - métodos

Agrupamiento jerárquico

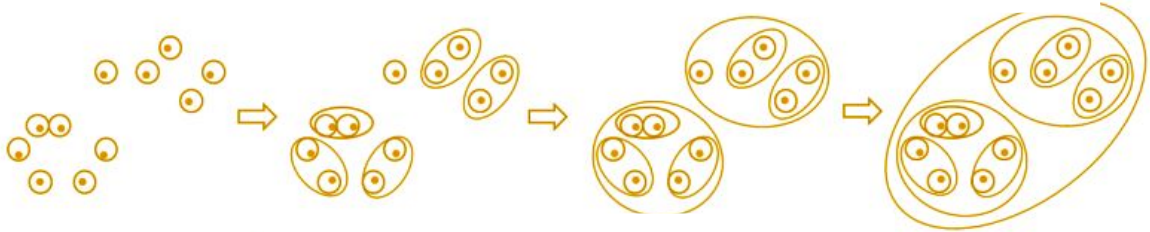
Agrupamiento jerárquico

Aglomerativo

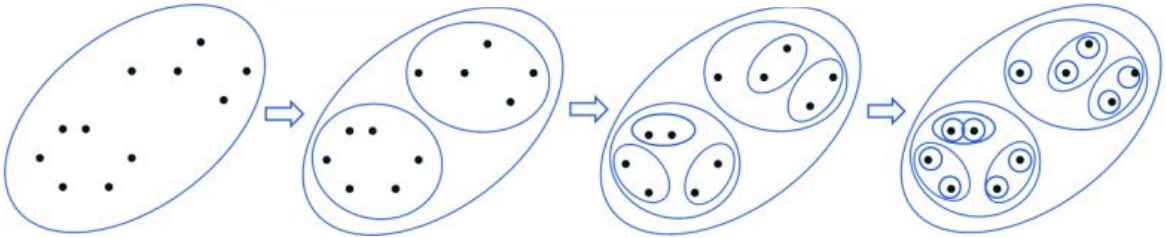


Agrupamiento jerárquico

Aglomerativo



Divisivo



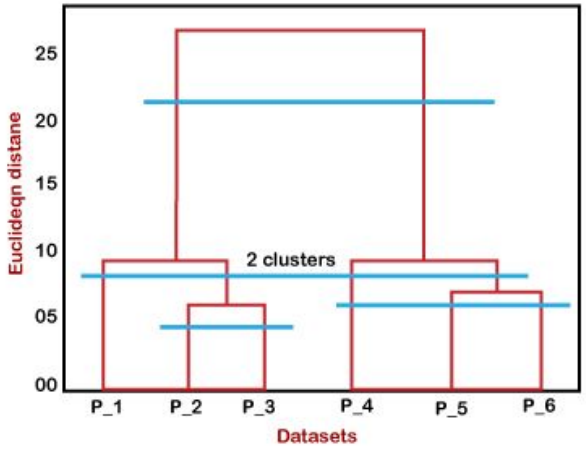
Agrupamiento jerárquico

- datos: P1, P2, P3, P4, P5 y P6
- calcular la matriz de distancia entre todos los datos

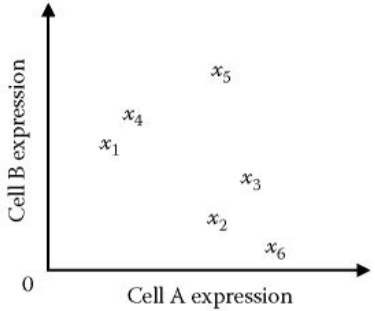
	P1	P2	P3	P4	P5	P6
P1	0.00					
P2	0.24	0.00				
P3	0.22	0.15	0.00			
P4	0.37	0.20	0.15	0.00		
P5	0.34	0.14	0.28	0.29	0.00	
P6	0.23	0.25	0.11	0.22	0.39	0.00

Agrupamiento jerárquico

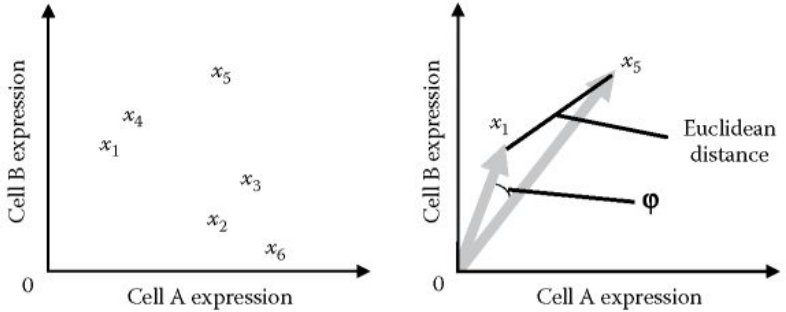
- dendograma



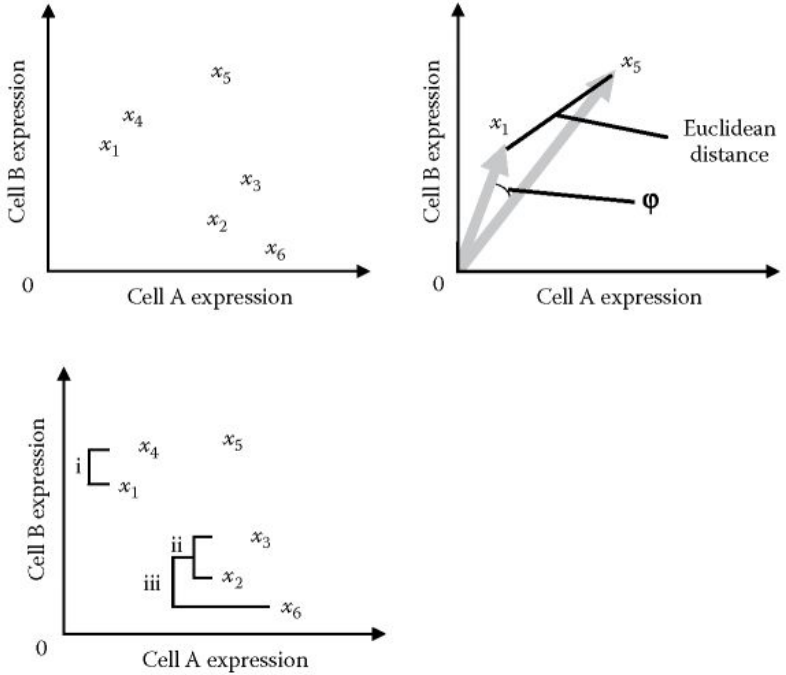
Agrupamiento jerárquico



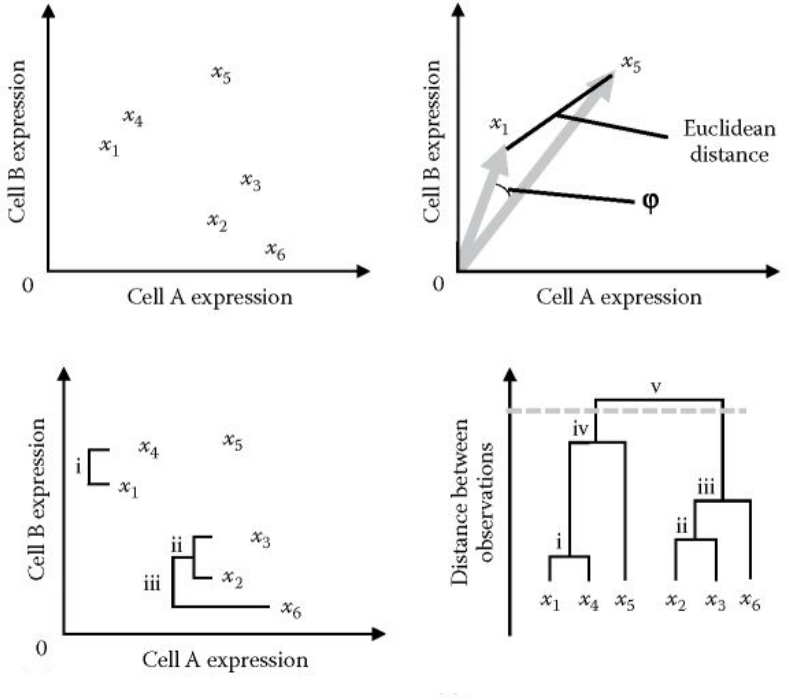
Agrupamiento jerárquico



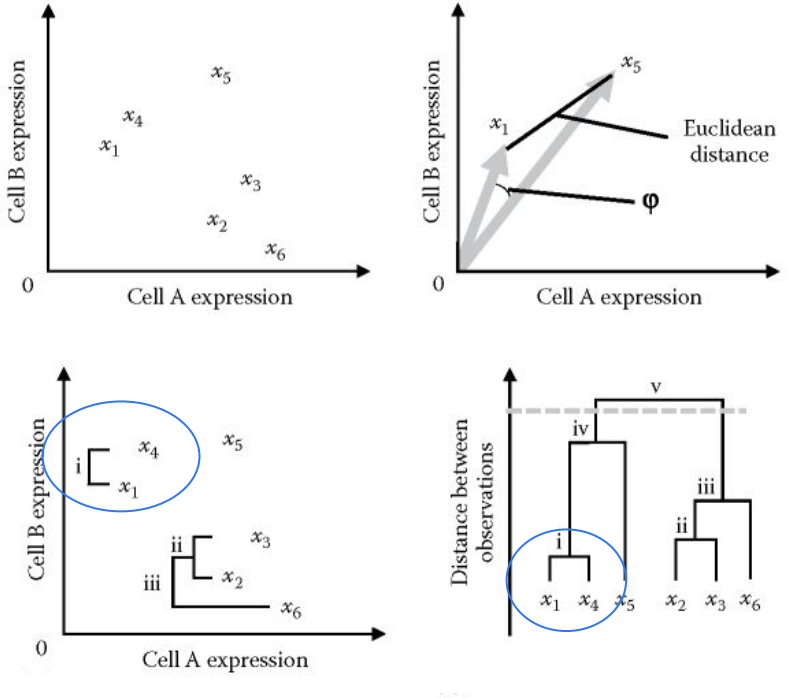
Agrupamiento jerárquico



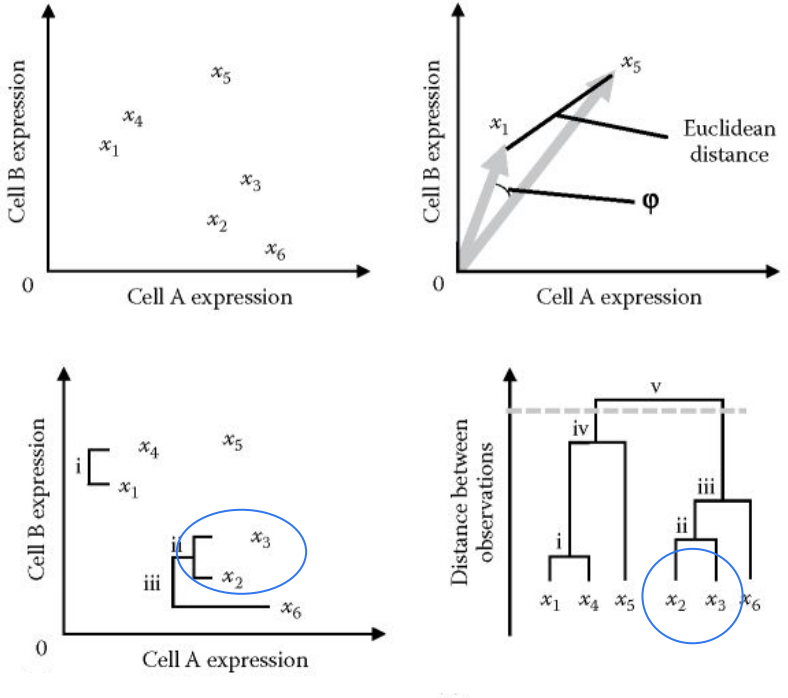
Agrupamiento jerárquico



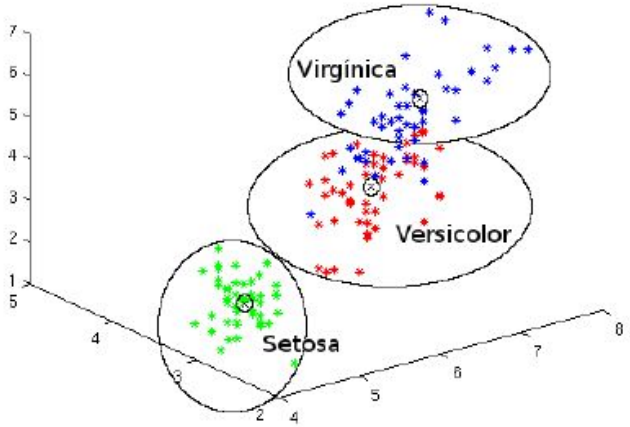
Agrupamiento jerárquico



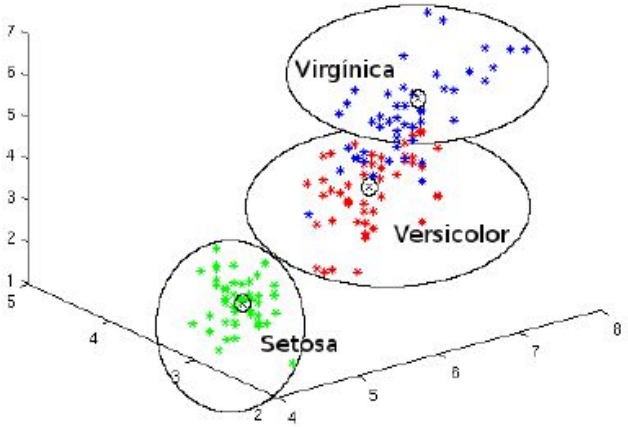
Agrupamiento jerárquico

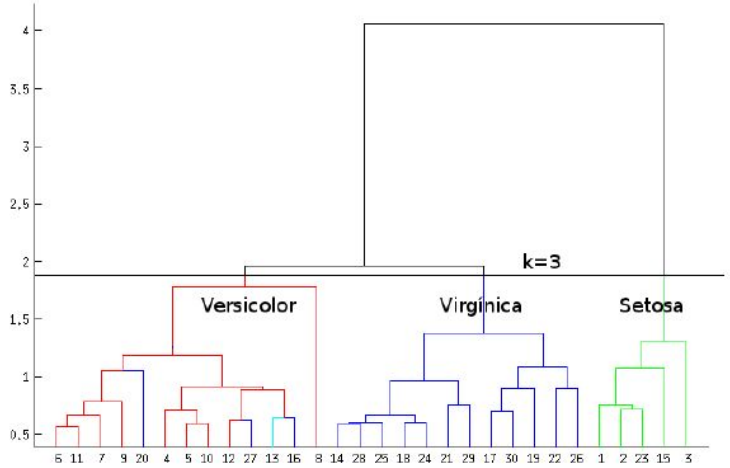


Agrupamiento jerárquico



Agrupamiento jerárquico





k-medias

k-medias

- Algoritmo muy popular y muy simple.
- Particiona los datos en *k* clusters.
- Utiliza centroides (prototipos de los clusters).

k-medias

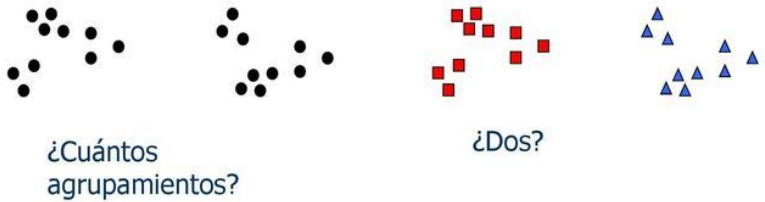
el problema del “k”



¿Cuántos
agrupamientos?

k-medias

el problema del “k”



k-medias

el problema del “k”



¿Cuántos agrupamientos?



¿Cuatro?

k-medias

el problema del “k”



k-medias

- *K-medias* es un algoritmo que agrupa objetos en *k* grupos basándose en sus características.
- Minimizando la suma de distancias entre cada objeto y el centroide de su grupo o cluster.
- Se suele usar la distancia euclídea.

k-medias

El algoritmo consta de tres pasos:

1) **Inicialización:** una vez elegido el número de grupos *k*, se establecen *k* centroides en el espacio de los datos aleatoriamente.
2) **Asignación objetos a los centroides:** cada objeto de los datos es asignado a su centroide más cercano.
3) **Actualización de centroides:** se actualiza la posición del centroide de cada grupo tomando como nuevo centroide la posición del promedio de los objetos pertenecientes a dicho grupo.

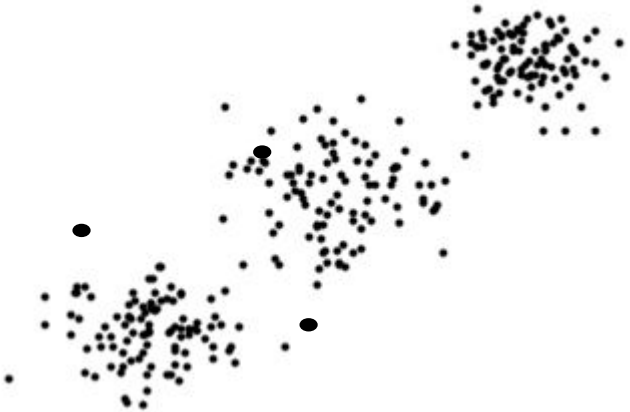
Se repiten los pasos 2 y 3 hasta que los centroides no se mueven.

k-medias

- Las principales ventajas del método *k-medias* son que es un método sencillo y rápido.
- Pero… es necesario decidir el valor de *k* *a-priori*
- El resultado final depende de la inicialización de los centroides.
- En principio no converge al mínimo global sino a un mínimo local.

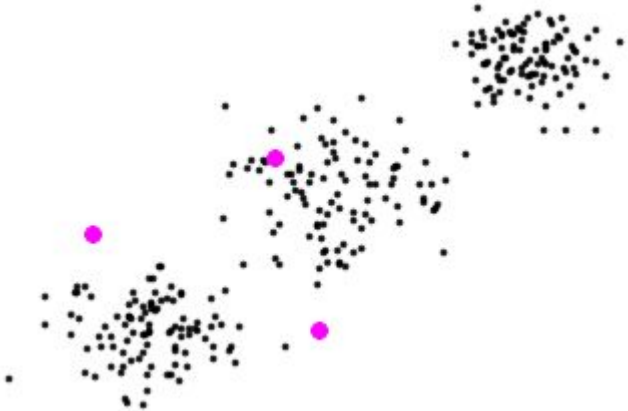
k-medias

Inicialización



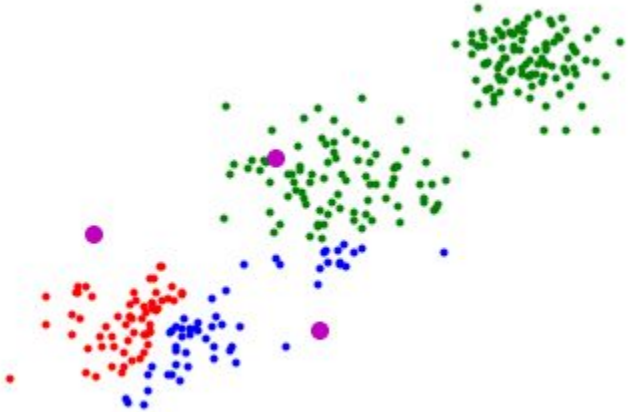
k-medias

Centroides random
k=3



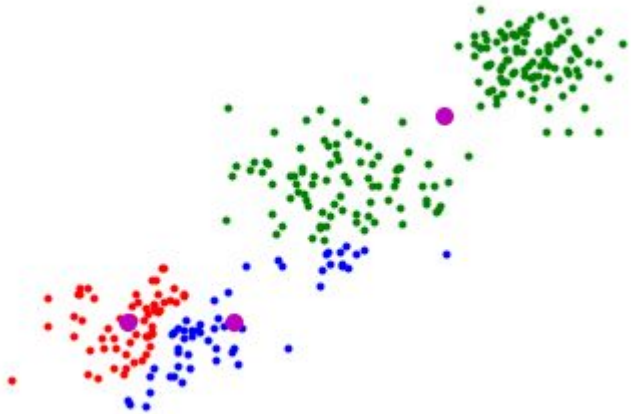
k-medias

Asignar puntos a centroides



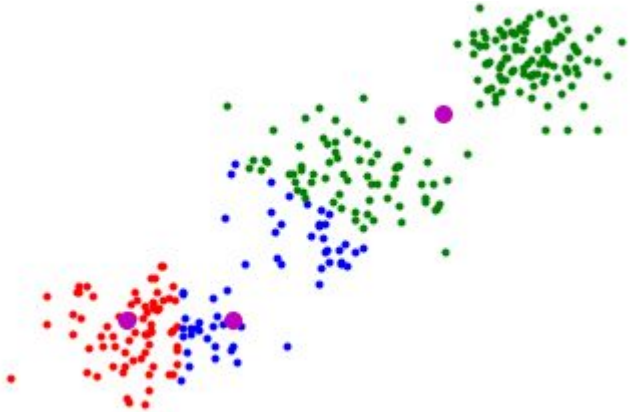
k-medias

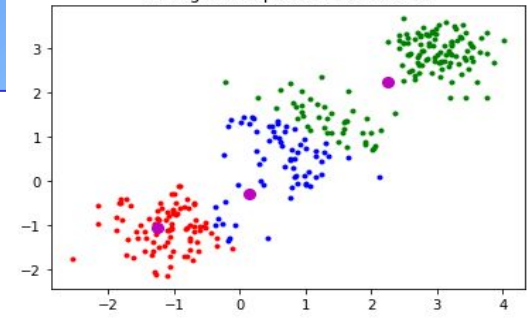
Re-ubicar centroides



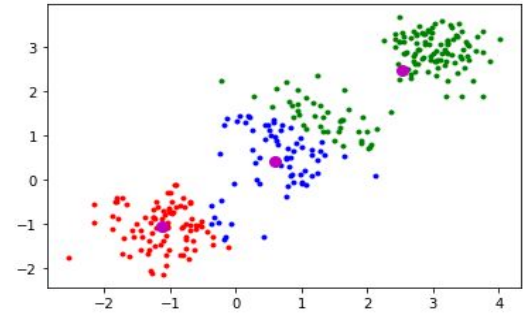
k-medias

Re-asignar puntos a centroides



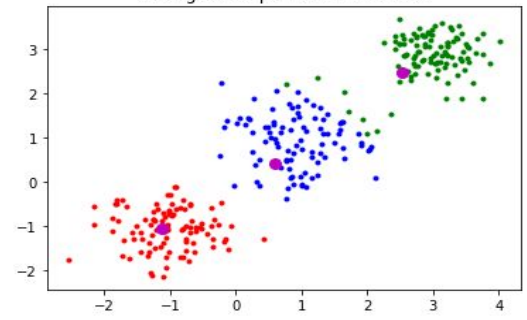


Reubicamos centroides



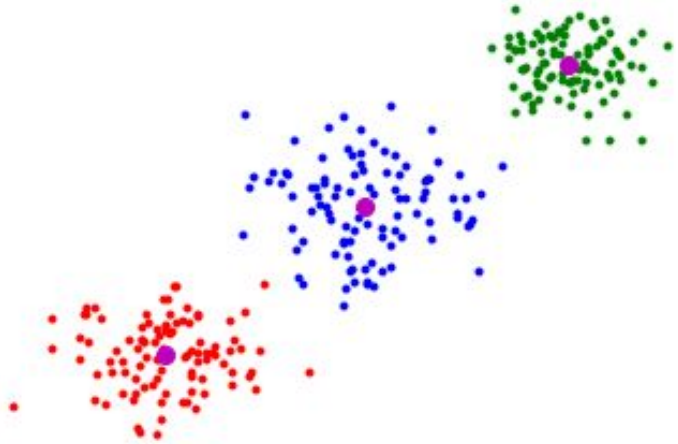
********** iteración 3

Reasignamos puntos a centroides



k-medias

Resultado final
(los centroides no
cambian más)



Métricas de clustering

Métricas de clustering

Cada algoritmo de clustering y combinación de parámetros produce particiones diferentes en los datos…

- por lo tanto, cómo evaluar los resultados obtenidos con varios algoritmos y varias configuraciones?
- como saber si la estructura encontrada por un algoritmo de clustering en los datos es válida?

Métricas de clustering

Por qué es necesaria la validación de resultado en clustering?

- => "bias" de los algoritmos: los algoritmos tienen un sesgo hacia las características de sus propias condiciones de funcionamiento. Por ejemplo, KM supone clusters esféricos y compactos.
- => clusters naturales: se supone que existe una estructura oculta en los datos. Sin embargo, aún cuando esa estructura no exista, los algoritmos de clustering siempre producen un resultado. Es necesario poder detectar su significancia (o no).

Métricas de clustering

Medidas internas:
Reciben como entradas los datos y las soluciones de clustering obtenidas, se evalúan según la información intrínseca de los datos

- Cohesión
- Separación
- Davies Bouldin
- …

Medidas externas:
Comparan varias soluciones entre sí, o contra una referencia (“gold standard”)

- FM
- Rand Index (RI)
- Jaccard, NMI, …

Métricas de clustering

Medidas internas:

Reciben como entradas los datos y las soluciones de clustering obtenidas, se evalúan según la información intrínseca de los datos

- Cohesión
- Separación
- Davies Bouldin

Métricas de clustering

Medida interna - Cohesión o compactness

- Evalúa que tan compactos u homogéneos son los clusters obtenidos por una solución. Se mide con la varianza intra-cluster:

$$\overline{C}_j = \frac{1}{|\Omega_j|} \sum_{\forall \mathbf{x}_i \in \Omega_j} \|\mathbf{x}_i - \mathbf{w}_j\|_2,$$

donde $|\Omega_j|$ es el número de datos en el cluster j, $\mathbf{w}_j$ es el centroide del cluster j, $\mathbf{x}_i$ es un dato agrupado en el cluster j.

- medida global de cohesión => promedio sobre todos los clusters
- cohesión cercana a 0 => clusters más compactos (mejor)

Métricas de clustering

Medida interna- Separación

Se cuantifica el grado de separación entre k clusters individuales. Esta separación puede ser evaluada por la distancia euclídea media, mínima y máxima entre los centroides $\mathbf{w}_i$ y $\mathbf{w}_j$ de los clusters:

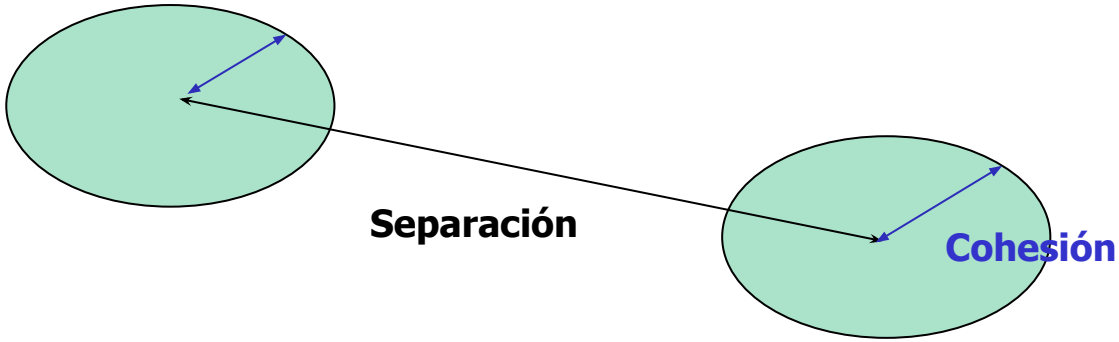
$$\overline{S} = \frac{2}{k^2 - k} \sum_{i=1}^{k} \sum_{j=i+1}^{k} \|\mathbf{w}_i - \mathbf{w}_j\|_2,$$

$$S_m = \min_{0<i\neq j\leq k} \{\|\mathbf{w}_i - \mathbf{w}_j\|_2\},$$

$$S_M = \max_{0<i\neq j\leq k} \{\|\mathbf{w}_i - \mathbf{w}_j\|_2\},$$

Separación cercana a 0 indica cercanía entre nodos.
Separación cercana a 1 => clusters más separados (mejor)

Métricas de clustering



Métricas de clustering

Medida combinada

cohesión media

$$DB = \frac{1}{k}\sum_{i=1}^{k}\max_{j\neq i}\left(\frac{\overline{C}_i + \overline{C}_j}{\|\mathbf{w}_i - \mathbf{w}_j\|_2}\right).$$

separación media

Índice de Davies-Bouldin: función de la relación entre la suma de las dispersiones intra-nodo y la separación entre nodos.

Medida del solapamiento entre nodos → privilegia agrupamientos compactos y bien separados entre sí.

Valores de DB cercanos a 0 indican poco solapamiento

Métricas de clustering

Medidas externas:

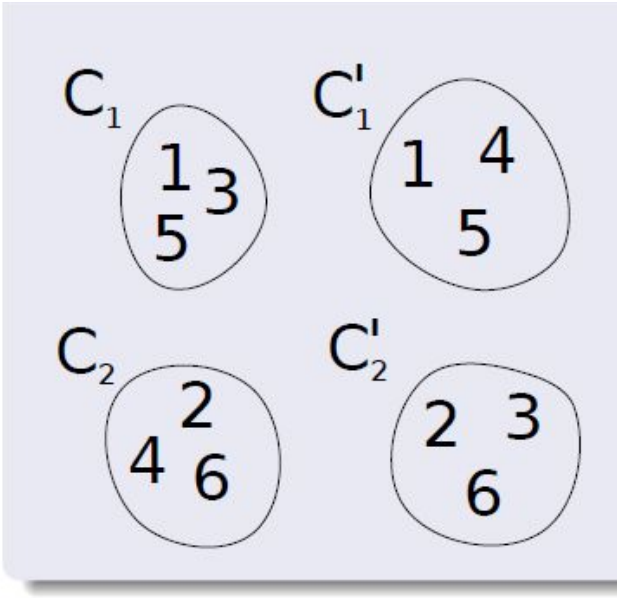
Comparan soluciones entre sí, o contra una referencia (“gold standard”)

- FM
- Rand Index (RI)

comparan la similitud existente **entre un par** de soluciones de clustering (S1 y S2)

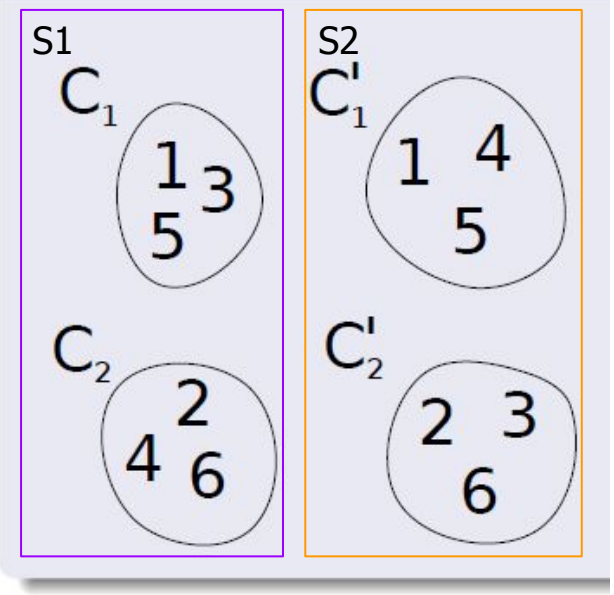
Métricas de clustering

Matriz de contingencia



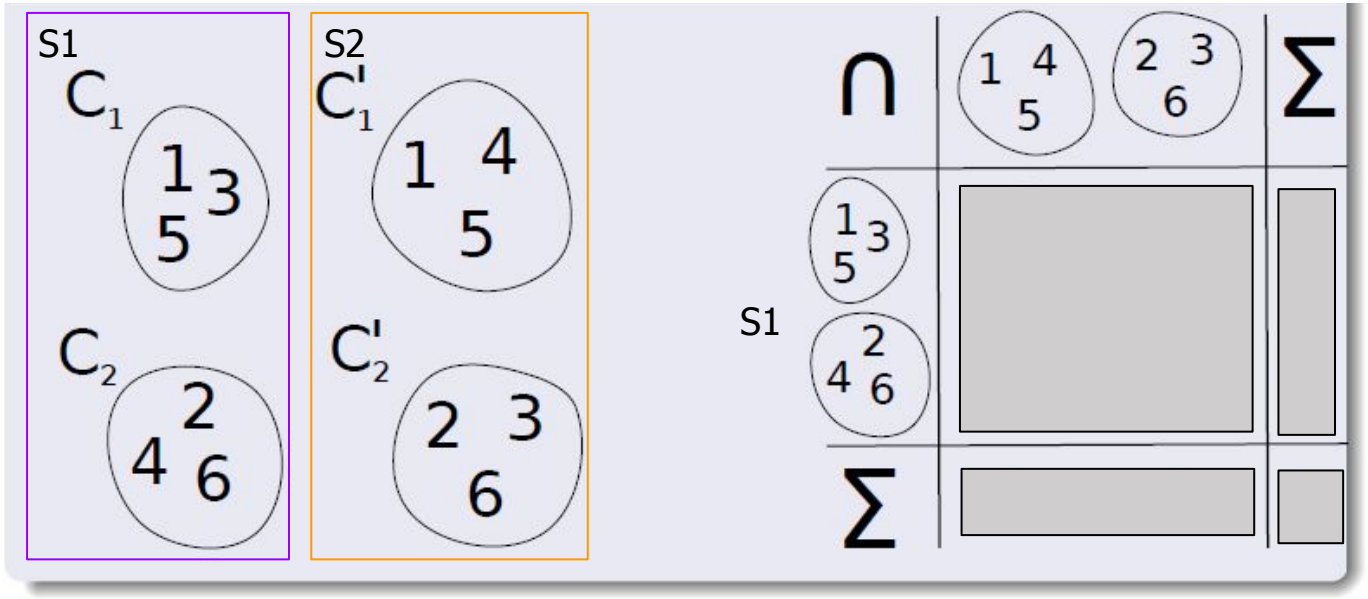
Métricas de clustering

Matriz de contingencia



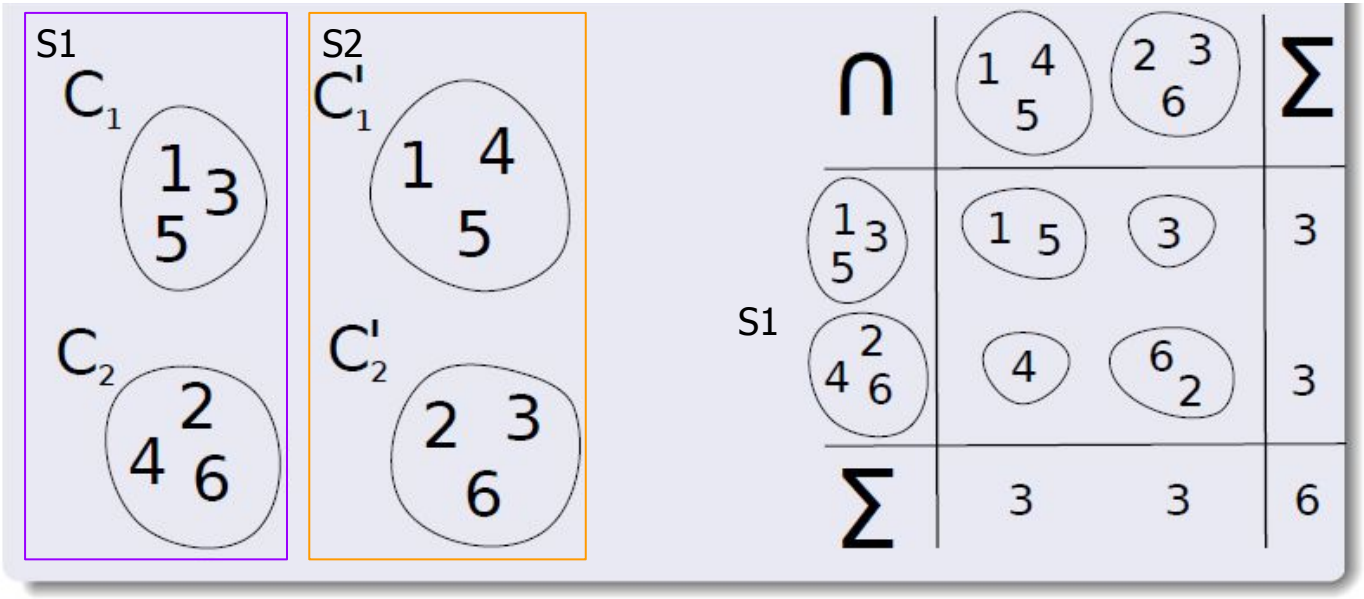
Métricas de clustering

Matriz de contingencia



Métricas de clustering

Matriz de contingencia



Métricas de clustering

Medida externa - Fowlkes and Mallows (FM)

Se utiliza para determinar la similitud entre dos particiones de clusterings (S1 y S2).

Puede ser entre un agrupamiento y una clasificación de referencia.

Un valor más alto (cercano a 1) para el índice de FM indica una mayor similitud entre las soluciones.

$$\mathrm{FMI} = \frac{\mathrm{TP}}{\sqrt{(\mathrm{TP}+\mathrm{FP})(\mathrm{TP}+\mathrm{FN})}}$$

donde:

TP: nro. de pares de puntos que están presentes en el mismo cluster en S1 y en S2

FP: nro. de pares de puntos que están presentes en el mismo cluster en S1 pero NO en S2

FN: nro. de pares de puntos que están presentes en el mismo cluster en S2 pero NO en S1

Métricas de clustering

Medida externa - Rand Index (RI)

Para 2 soluciones S1 y S2, medimos:

a) nro. de pares de elementos que están en el mismo conjunto en S1 y S2
b) nro. de pares de elementos que están en conjuntos diferentes en S1 y en conjuntos diferentes en S2

El índice de Rand es: $$\mathrm{RI} = \frac{a+b}{C_2^{n_{samples}}}$$

donde el denominador es el número total de pares posibles en el conjunto de datos.

El etiquetado perfecto tiene una puntuación de 1.

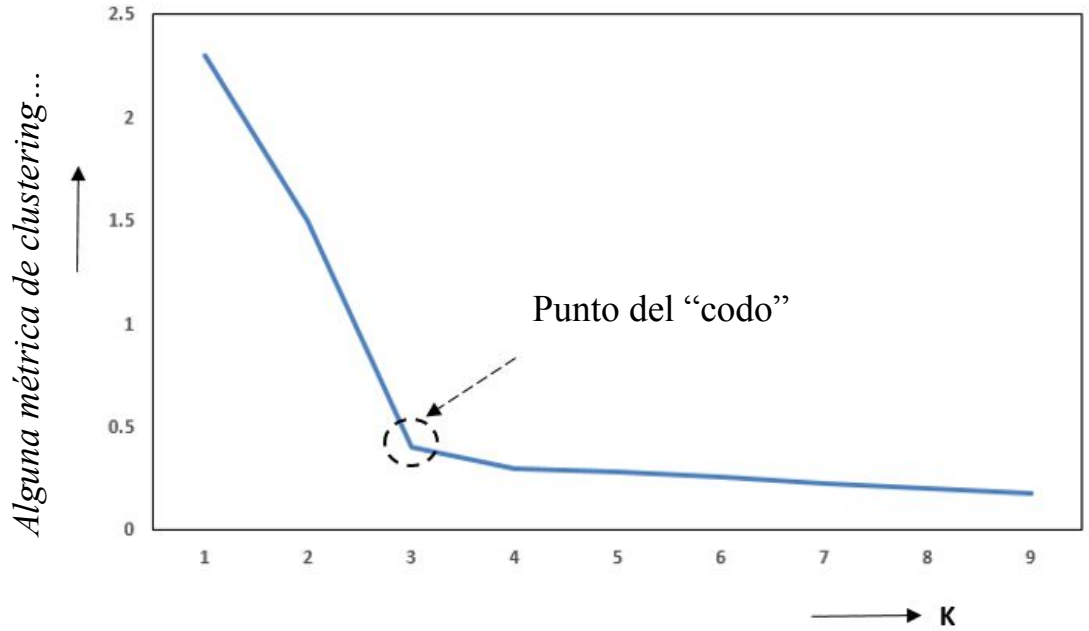
Métricas de clustering - el k óptimo

El número de clusters (k)

Las métricas de clustering pueden ser usadas para estimar el número adecuado de clusters para un dataset.

- Eso involucra calcular los resultados de una métrica de clustering para un rango de valores de k, y plotear la curva resultante.
- El mejor nro. de clusters puede determinarse como un “pico” o “codo” en la curva de performance obtenida.

Métricas de clustering - el k óptimo



El método “del codo” (*elbow* method en inglés)

Bibliografía

- R. Xu and D. Wunsch (2008) Clustering. Ed. John Wiley & Sons.
- M. Halkidi, Y. Batistakis, M. Vazirgiannis (2001) On clustering validation techniques. Journal of Intelligent Informations Systems, vol. 17, no. 1, pp. 107–145.
- D. Davies, D. Bouldin (1979) A Cluster Separation Measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. PAMI-1 (2): 224–227.
- W. M. Rand (1971) Objective criteria for the evaluation of clustering methods.Journal of the American Statistical Association, vol. 66, no. 336, pp. 846–850, 1971.
- P. Dangeti (2017) Statistics for Machine Learning. Ed. O´Reilly Publishing.

Georgina Stegmayer
gstegmayer@sinc.unl.edu.ar