UNIDAD 6 — Inteligencia Colectiva 2

Inteligencia de enjambres

1. Colonia de hormigas:

La inspiración biológica

- Hay 10^{16} hormigas en la tierra (y 6×10^9 humanos).
- Igual peso total.
- 30 millones por colonia.
- ***Feromonas:*** *la búsqueda del camino más corto a la comida.*
  1. Comportamiento inicial aleatorio
  2. Cuando encuentran una fuente de comida se organizan y comienzan a seguir el mismo camino

     2.1. Mecanismo de reclutamiento: mayormente por **feromonas**, liberadas al regresar (algunas las liberan en proporción a la cantidad de alimento encontrado).

     2.2 Si otras encuentran feromonas siguen el rastro (con más probabilidad, tratando de alejarse del hormiguero si no llevan comida).

     2.3 El camino **se refuerza** al ser seguido por más y más hormigas.

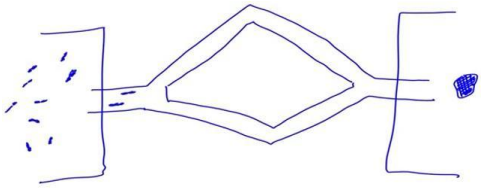
Notar:

- **Comunicación indirecta**
- Modificación del entorno físico: **estigmergia**.

Experimento del puente binario

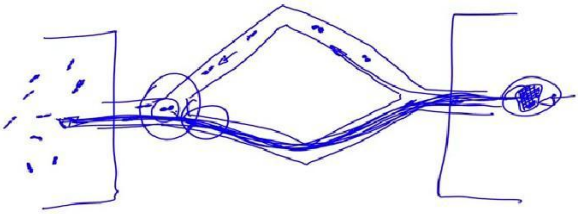
→ dió origen a los algoritmos que surgieron después.

Tenemos 2 mesas a cierta distancia, vistas de arriba, y entre medio de ellas tenemos un puente que tiene 2 brazos, uno más largo y otro más corto.
En una de las mesas tenemos hormigas que se empiezan a mover aleatoriamente hasta que algunas empiezan a transitar por el puente. Vamos a suponer que, con alguna probabilidad, 2 hormigas que van juntas exploran un camino cada una, el de arriba y el de abajo.



La hormiga que vaya por el más corto va a descubrir la comida primero. Una vez que llegó, y lo descubrió, va a volver por donde vino, y la otra que también llegó pero más tarde hará lo mismo.

Cuando una nueva hormiga quiera transitar por el puente, va a llegar a la bifurcación y tiene que tomar la decisión de ir por arriba o por abajo. *Muy probablemente* (la preferencia no es absoluta), perciba que *hay más feromonas en el camino más corto, lo cual va a seguir reforzando este camino*, hasta llegar al punto de que la *decisión de las hormigas en la bifurcación sea directa*.



=> encontraron el camino óptimo.

Colonia de hormigas: algoritmos

Definiciones:

- ***G = (V, E):*** grafo con *vértices o nodos* ***V*** (puntos donde va pasando la hormiga) y *matriz de conexiones* ***E*** entre esos puntos.
- σ_{ij}: cantidad de feromonas en la conexión entre **i** y **j**
- ***k = 1, 2, . . . , N***: hormigas
- ***Ni***: nodos disponibles a partir del nodo **i**, para cada nodo.
- $p^k(t)$***:*** camino de la hormiga **k** (lista de nodos por los que fue pasando), va a ir cambiando con el tiempo.

Notar:

- **t → t + 1:** se incrementa una vez que ***todas*** las hormigas encuentran el alimento y vuelven al origen.

- $\mathbf{N}^k$: denota los nodos disponibles *para la hormiga* ***k***. En algunos casos el entorno se limita a los nodos que *no haya visitado previamente la hormiga* ***k***.

Algoritmo 1: Colonia de hormigas simple (sACO)

1. $t = 0$, Inicializar feromonas con valores pequeños al azar $(\sigma_{ij}(t) \rightsquigarrow U(0, \sigma_0))$
2. Ubicar N hormigas en el nodo origen
3. **repetir**
   - 3.1 **para** cada hormiga $k = 1, 2, \ldots, N$
     - 3.1.1 $\mathbf{p}^k(t) = \varnothing$ → Lista de nodos por los que pasó la hormiga = vacío
     - 3.1.2 **repetir**
       - seleccionar el próximo nodo según la *probabilidad* $p_{ij}^k(t) = \cdots$

$$p_{ij}^k(t) = \begin{cases} \dfrac{\sigma_{ij}^{\alpha}(t)}{\sum_{\forall u \in N_i} \sigma_{iu}^{\alpha}(t)} & \text{si } j \in N_i \\ 0 & \text{en otro caso.} \end{cases}$$

→ Incorporamos el exponente alpha, que nos permite potenciar el efecto de esa cantidad de feromonas

       - agregar un paso (i, j) al camino $\mathbf{p}^k(t)$

       hasta *alcanzar el destino*

     - 3.1.3 eliminar los ciclos en $\mathbf{p}^k(t)$
     - 3.1.4 calcular la longitud del camino econtrado $f\left(\mathbf{p}^k(t)\right)$

   - 3.2 **para** cada conexión (i, j)
     - reducir por evaporación la cantidad de feromonas: $\sigma_{ij}(t) \leftarrow (1 - \rho)\sigma_{ij}(t)$

   Tasa de evaporación de la feromona

   - 3.3 **para** cada conexión (i, j)
     - depositar feromonas proporcionalmente a la bondad de la solución

$$\sigma_{ij}(t+1) = \sigma_{ij}(t) + \sum_{\forall k/(i,j) \in \mathbf{p}^k(t)} 1/f\left(\mathbf{p}^k(t)\right)$$

→ inversamente proporcional al camino de esa hormiga

→ sumando los aportes de todas las hormigas a esa intersección

   - 3.2 **para** cada conexión (i, j)
     - reducir por evaporación la cantidad de feromonas: $\sigma_{ij}(t) \leftarrow (1 - \rho)\sigma_{ij}(t)$
   - 3.3 **para** cada conexión (i, j)
     - depositar feromonas proporcionalmente a la bondad de la solución

$$\sigma_{ij}(t+1) = \sigma_{ij}(t) + \sum_{\forall k/(i,j) \in \mathbf{p}^k(t)} 1/f\left(\mathbf{p}^k(t)\right)$$

   - 3.4 $t \leftarrow t + 1$

   hasta que *todas* las hormigas sigan el mismo camino
4. **devolver** el camino más corto $(\downarrow f\left(\mathbf{p}^k(t)\right))$

Algoritmo 2: Sistema de hormigas (AS)

1. $t = 0, \sigma_{ij}(t) \rightsquigarrow U(0, \sigma_0)$
2. Ubicar N hormigas en el nodo origen
3. **repetir**
   - 3.1 **para** cada hormiga $k = 1, 2, \ldots, N$
     - 3.1.1 $\mathbf{p}^k(t) = \varnothing$
     - 3.1.2 **repetir**
       - seleccionar el próximo nodo según la *probabilidad*

$$p_{ij}^k(t) = \begin{cases} \dfrac{\sigma_{ij}^{\alpha}(t)\eta_{ij}^{\beta}(t)}{\sum_{\forall u \in N_i^k} \sigma_{iu}^{\alpha}(t)\eta_{ij}^{\beta}(t)} & \text{si } j \in N_i^k \\ 0 & \text{en otro caso.} \end{cases}$$

       → Deseo de moverse inverso al costo entre nodos: $\eta_{ij} = 1/d_{ij}$.

       → Lista de nodos vecinos con tabú: N_i^k — lista sin nodos por los que ya pasó la hormiga, evita que se generen ciclos

       - agregar un paso (i, j) al camino $\mathbf{p}^k(t)$

       hasta *alcanzar el destino*

     - 3.1.3 calcular la longitud del camino econtrado $f\left(\mathbf{p}^k(t)\right)$
   - 3.2 **para** cada conexión (i, j)
     - reducir por evaporación la cantidad de feromonas: $\sigma_{ij}(t) \leftarrow (1 - \rho)\sigma_{ij}(t)$
     - depositar feromonas proporcionalmente a la bondad de la solución

$$\Delta\sigma_{ij}^k(t) = \begin{cases} Q/f\left(\mathbf{p}^k(t)\right) & \text{global.} \\ Q & \text{uniforme.} \\ Q/d_{ij} & \text{local.} \end{cases}$$

Alternativas de incremento de feromonas

$$\sigma_{ij}(t+1) = \sigma_{ij}(t) + \sum_{\forall k/(i,j) \in \mathbf{p}^k(t)} \Delta\sigma_{ij}^k(t)$$

   - 3.3 $t \leftarrow t + 1$

   hasta que *todas* las hormigas sigan el mismo camíno
4. **devolver** el mejor camino

2. Enjambre de partículas:

La inspiración biológica

- Bandadas de pájaros.
- Cada individuo vuela/navega el espacio *ajustando su posición en base a su* ***experiencia propia*** *y a la información de los individuos de su entorno, la* ***experiencia de su entorno***.
- Emular el éxito de los vecinos y propio.
- Tenemos 2 variables fundamentales:
  - $x^k(t)$: posición de la partícula **k**, en el tiempo **t** (espacio R^N)
  - $v^k(t)$: velocidad de la partícula **k**, en el tiempo **t**
- Regla básica: $\mathbf{x}_k(t+1) = \mathbf{x}_k(t) + \mathbf{v}_k(t)$

Definiciones:

- y_k: mejor posición personal de la partícula k (la mejor que visitó desde t = 0 hasta la actualidad) → aquella con menor error para el problema a resolver.
- ***f(x)***: *función de error* a minimizar.

Mejor global (gEP):

- *Topología **estrella***: usa *info. de todo el enjambre* → ***información social global***
- $\hat{y}$: mejor posición visitada por todo el enjambre

Algoritmo 3: Enjambre del mejor global (gEP)

1. Inicializar $\mathbf{x}_{ki}(0) \rightsquigarrow U(\mathbf{x}_i^{min}, \mathbf{x}_i^{max})$ → Para cada variable i de los vectores posición x
2. **repetir**
   - 2.1 **para** cada partícula $k = 1, 2, \ldots, N$
     - **si** $f(\mathbf{x}_k(t)) < f(\mathbf{y}_k) \rightarrow \mathbf{y}_k = \mathbf{x}_k(t)$ → Ver si la posición actual es mejor que su mejor posición individual
     - **si** $f(\mathbf{y}_k) < f(\hat{\mathbf{y}}) \rightarrow \hat{\mathbf{y}} = \mathbf{y}_k$ → Ver si la posición actual es mejor que la mejor posición global
   - 2.2 **para** cada partícula $k = 1, 2, \ldots, N$
     - $v_{ki}(t+1) = v_{ki}(t) + c_1 r_{1i}\left[y_{ki} - x_{ki}(t)\right]$ → experiencia personal
       $+ c_2 r_{2i}\left[\hat{y}_i - x_{ki}(t)\right]$ → experiencia social

       velocidad del individuo k en la dimensión i

       $r_{1i}, r_{2i} \rightsquigarrow U(0,1)$

       c → constante de aceleración

       r → constante aleatoria entre 0 y 1.
     - $\mathbf{x}_k(t+1) = \mathbf{x}_k(t) + \mathbf{v}_k(t+1)$

   hasta cumplir con la condición de finalización
3. **devolver** la mejor partícula encontrada

Variante - Enjambre de partículas

Definiciones:

- y_k: mejor posición personal de la partícula k (la mejor que visitó desde t = 0 hasta la actualidad) → aquella con menor error para el problema a resolver.
- ***f(x)***: *función de error* a minimizar.

Mejor global (gEP):

- *Topología **anillo***: usa *info. del entorno cercano a la partícula* → ***información social global acotada a un entorno***
- Selección: basada en los índices de las partículas (caso más simple)

$$\mathcal{E}_k = \{\mathbf{y}_{k-n}, \mathbf{y}_{k-n+1}, \ldots, \mathbf{y}_{k-1}, \mathbf{y}_k, \mathbf{y}_{k+1}, \ldots, \mathbf{y}_{k+n}\}:$$ vecindad

- $\hat{\mathbf{y}}_k = \arg\min_{\forall \mathbf{y}_u \in \mathcal{E}_k} \{f(\mathbf{y}_u)\}$ mejor posición visitada por el entorno de la partícula k → para todas las mejores posiciones individuales que alcanzaron las partículas vecinas de k, las recorremos y buscamos el mínimo, y la definimos como la mejor local.

Algoritmo 4: Enjambre del mejor local (ℚEP)

1. Inicializar $\mathbf{x}_{ki}(0) \rightsquigarrow U(\mathbf{x}_i^{min}, \mathbf{x}_i^{max})$
2. **repetir**
   2.1 **para** cada partícula $k = 1, 2, \ldots, N$
   - **si** $f(\mathbf{x}_k(t)) < f(\mathbf{y}_k) \rightarrow \mathbf{y}_k = \mathbf{x}_k(t)$
   - **si** $f(\mathbf{y}_k) < f(\hat{\mathbf{y}}) \rightarrow \hat{\mathbf{y}} = \mathbf{y}_k$

   2.2 **para** cada partícula $k = 1, 2, \ldots, N$
   - $v_{ki}(t+1) = v_{ki}(t) + c_1 r_{1i} [y_{ki} - x_{ki}(t)] + c_2 r_{2i} [\hat{y}_{ki} - x_{ki}(t)]$

     $r_{1i}, r_{2i} \rightsquigarrow U(0,1)$

     $\hat{\mathbf{y}}_k = \arg\min_{\forall \mathbf{y}_u \in \mathcal{E}_k} \{f(\mathbf{y}_u)\}$

     → Aparece k porque ahora la información social depende de cada partícula k, no es la misma para todas.
   - $\mathbf{x}_k(t+1) = \mathbf{x}_k(t) + \mathbf{v}_k(t+1)$

   hasta cumplir con la condición de finalización
3. **devolver** la mejor partícula encontrada