# Predictor para el ganador del premio MVP de NBA

**S.D. Bargas, J. Grinovero, A.R. Telli,**
Facultad de Ingeniería y Ciencias Hídricas, Universidad Nacional del Litoral

## Resumen

En este documento se explican los procedimientos para la construcción de un predictor del ganador MVP de la NBA utilizando Python. Primero se presentarán los conceptos fundamentales del análisis de datos deportivos y las métricas clave empleadas para la evaluación de jugadores. Luego, se describirán los métodos de aprendizaje automático y las técnicas de preprocesamiento utilizadas en la implementación del predictor. Se mostrarán los resultados obtenidos a través de distintas métricas de evaluación y se los comparará con otros enfoques existentes. Finalmente, se ofrecerán conclusiones sobre el rendimiento del modelo y posibles mejoras futuras.

## 1. Introducción

En el mundo del baloncesto profesional, la elección del Jugador Más Valioso (MVP) es un tema de gran interés tanto para analistas como para aficionados. Predecir qué jugadores tienen mayores posibilidades de recibir este galardón representa un desafío complejo que involucra análisis de datos, tendencias históricas y desempeño actual en la NBA. Este tipo de predicciones puede ser aplicado en áreas como el periodismo deportivo, apuestas deportivas y estudios de rendimiento, proporcionando valor a largo plazo y fomentando nuevas perspectivas analíticas en el deporte.

El objetivo de este trabajo es desarrollar un modelo predictivo que identifique al ganador del premio MVP de la NBA, utilizando herramientas de aprendizaje automático en Python. El modelo se alimenta de métricas clave como puntos, asistencias, rebotes, eficiencia y otras estadísticas avanzadas que reflejan el desempeño de los jugadores en una temporada.

El trabajo se enfoca en aplicar técnicas de aprendizaje supervisado para analizar datos reales y construir un modelo capaz de predecir con precisión a los jugadores con mayores probabilidades de ser MVP. En las próximas secciones se describen detalladamente los pasos seguidos en la implementación del modelo, los resultados obtenidos, su comparación con otros métodos similares y las conclusiones derivadas del análisis.

## 2. Desarrollo

En este trabajo práctico, se utilizaron modelos de aprendizaje automático para realizar la tarea de clasificación y predicción del jugador candidato a ganar el MVP de la NBA en función de un conjunto de características estadísticas de su desempeño. Los modelos utilizados fueron:

- **MLPRegressor:** Explora la capacidad de las redes neuronales para modelar relaciones no lineales complejas. Este modelo se basó en un perceptrón multicapa para encontrar patrones en los datos.
- **RandomForestRegressor:** Un método de ensamble basado en árboles de decisión que captura patrones al combinar múltiples modelos individuales.

A lo largo del análisis, se ajustaron diversos hiperparámetros para maximizar el desempeño de estos modelos, evaluando su precisión en un conjunto de datos de validación.

### 2.1. La base de datos

Para trabajar en este proyecto, se utilizó la página oficial de la NBA que provee una cantidad inmensa de características, por año, por jugador, por equipo, etc. [1]
Esta plataforma resulta ideal para recopilar estadísticas detalladas tanto a nivel individual como colectivo.

El proceso comenzó con la extracción de estadísticas anuales, diferenciando entre dos categorías principales:

- **Estadísticas de jugadores**: se centran en el rendimiento individual de cada jugador. Incluyen métricas como:
  - Puntos anotados.
  - Asistencias.
  - Rebotes.
  - Minutos jugados.
  - Entre otras métricas clave.
- **Estadísticas de equipos**: Se enfocan en el rendimiento colectivo del equipo. Incluyen métricas como:
  - Número de victorias y derrotas.
  - Puntos promedio por partido.
  - Eficiencia defensiva.
  - Entre otros aspectos del desempeño del equipo.

Para facilitar la recopilación de estos datos, se desarrolló un sistema automatizado que descarga las estadísticas desde la web y las almacena en archivos `.csv`. Este proceso permite parametrizar aspectos como el año y el tipo de estadística deseada. La URL empleada para acceder a la información tiene el siguiente formato:

`https://www.basketball-reference.com/leagues/NBA_{year}_{stat_type}.html`

Donde:

- `{year}` corresponde al año específico de la temporada.
- `{stat_type}` define el tipo de estadística requerida (por ejemplo, totales, por partido, avanzadas, entre otras).

Además, durante el procesamiento de las estadísticas de jugadores, se fusionan múltiples tablas relacionadas con diferentes categorías de datos, como, estadísticas acumuladas por temporada, promedios por partido,tipos de tiro y su precisión.
También se agregaron estadísticas avanzadas como:

- *Player Efficiency Rating* (PER): Métrica que evalúa el rendimiento de un jugador en función de su contribución estadística en diversos aspectos del juego (puntos, rebotes, asistencias, robos, bloqueos, etc.), ajustada al ritmo del equipo
- *True Shooting Percentage* (TS): Métrica que mide la eficiencia de un jugador al anotar, considerando todos los tipos de tiros (tiros de campo, tiros de tres puntos y tiros libres). Es más precisa que el porcentaje de tiros de campo tradicional porque tiene en cuenta el valor adicional de los triples y la importancia de los tiros libres

Y adicionalmente, se incorporan datos relacionados con premios individuales obtenidos por los jugadores en cada temporada. Estos reconocimientos permiten identificar a los mejores jugadores en diversas categorías, como:

- `mvp`: Jugador más valioso (*Most Valuable Player*).

- `roy`: Novato del año (*Rookie of the Year*).
- `dpoy`: Mejor jugador defensivo (*Defensive Player of the Year*).
- `smoy`: Mejor sexto hombre (*Sixth Man of the Year*).
- `mip`: Jugador con mayor progreso (*Most Improved Player*).
- `clutch_poy`: Jugador más decisivo (*Clutch Player of the Year*).
- `leading_all_nba`: Selección para el equipo ideal de la NBA (*All-NBA Team*).
- `leading_all_defense`: Selección para el equipo ideal defensivo (*All-Defensive Team*).
- `leading_all_rookie`: Selección para el equipo ideal de novatos (*All-Rookie Team*).

Este enriquecimiento garantiza que la tabla final de jugadores incluya una visión integral del rendimiento individual para cada temporada. Además, durante el proceso, se resuelven problemas de duplicados (como jugadores que cambian de equipo) para consolidar los datos en una sola fila por jugador, manteniendo detalles clave como el último equipo en el que jugó.

Una vez recopiladas las diferentes tablas de estadísticas, estas se combinan en una única tabla consolidada para cada temporada. El proceso de combinación utiliza la función `merge`, que une las tablas basándose en el índice común, correspondiente al identificador único del jugador (`playerId`). Esto permite alinear correctamente las métricas de cada jugador provenientes de diferentes fuentes, asegurando que todas las estadísticas relacionadas se agrupen en una única fila por jugador.

Una vez que se realizó el proceso de filtrado de características y se estructuró adecuadamente la tabla de datos, se obtuvieron 80 columnas, correspondientes a 80 características que consideramos fundamentales para el testing. Estas características fueron seleccionadas en base a su relevancia e impacto en el análisis, garantizando que representen de manera eficiente la información necesaria.

### 2.1.1. Filtrado de jugadores

Dado que, en promedio, existen aproximadamente 500 jugadores activos por temporada en la NBA, se realizó un filtrado adicional con el fin de optimizar el análisis y enfocarse en los jugadores con mayor impacto en el juego. Este filtrado se basó en un criterio clave: los minutos jugados por temporada.

Los minutos jugados son una métrica fundamental, ya que reflejan el tiempo que un jugador pasa en la cancha, lo cual está directamente relacionado con su nivel de participación e importancia dentro del equipo. Por ello, se seleccionaron únicamente los 100 jugadores con más minutos jugados en cada temporada. Este enfoque asegura que los datos incluyan a los jugadores más relevantes, particularmente para análisis como la elección del *Most Valuable Player* (MVP), donde los minutos jugados suelen ser un factor importante a considerar. Este filtrado permite reducir significativamente la cantidad de datos procesados, asegurando al mismo tiempo que la calidad del análisis no se vea comprometida, ya que se consideran a los jugadores con mayor protagonismo en sus respectivas temporadas.

## 2.2. Patrón de características

En el proyecto, se decidió utilizar el rendimiento de un jugador por año como patrón debido a la naturaleza dinámica y cambiante del baloncesto a lo largo del tiempo. El juego ha evolucionado significativamente, con cambios en el estilo de juego, la velocidad, el físico, las tácticas y las reglas, lo que ha influido en las métricas clave utilizadas para evaluar a los jugadores. Por ejemplo, en décadas pasadas, ciertos logros estadísticos, como promediar 20 puntos por partido, eran indicativos de un rendimiento destacado y un fuerte candidato al MVP. Sin embargo, hoy en día, con la globalización del juego, las características de un candidato a MVP en los años pasados a comparación con las características actuales no sería considerado para ser ganador del premio. Los jugadores actuales deben destacar no solo por sus estadísticas ofensivas, sino también por su versatilidad y capacidad para influir en todas las áreas del juego, lo que hace que el perfil de un candidato al MVP sea mucho más complejo y multidimensional. Así, el patrón basado en el rendimiento por año nos permite observar cómo estos cambios afectan la evaluación de los jugadores a lo largo del tiempo.

## 3. Clasificadores Utilizados

### 3.1. MLPRegressor

El `MLPRegressor` Es un modelo de aprendizaje automático basado en redes neuronales artificiales, diseñado específicamente para resolver problemas de regresión. Utiliza un enfoque de aprendizaje supervisado, donde aprende patrones a partir de un conjunto de datos etiquetados para realizar predicciones sobre valores continuos.

- **Arquitectura de red neuronal:** El `MLPRegressor` utiliza una red neuronal multicapa (Multilayer Perceptron, de donde proviene su nombre) que está compuesta por:
  - Una **capa de entrada**, que recibe las características o variables del conjunto de datos.
  - Una o más **capas ocultas**, donde se realiza el procesamiento no lineal.
  - Una **capa de salida**, que genera las predicciones.
- **Proceso de aprendizaje:** Durante el entrenamiento, el modelo ajusta sus parámetros internos (los pesos y sesgos de las conexiones entre las neuronas) para minimizar el error entre las predicciones y los valores reales. Este ajuste se realiza mediante el algoritmo de *backpropagation*, en conjunto con un optimizador como *Stochastic Gradient Descent* o *Adam*.

### 3.2. Random Forest Regressor

El **Random Forest Regressor** es un modelo de aprendizaje supervisado que utiliza un conjunto de árboles de decisión para realizar tareas de regresión. Este modelo pertenece a la familia de métodos de ensamble y combina las predicciones de múltiples árboles de decisión entrenados independientemente. La combinación de múltiples modelos reduce el riesgo de sobreajuste y mejora la capacidad de generalización.

- **Funcionamiento:** Combina las predicciones de múltiples árboles de decisión entrenados sobre muestras aleatorias de los datos. La predicción final se obtiene como el promedio de las predicciones de todos los árboles.
- **Regularización:** El modelo incluye hiperparámetros clave como el número de árboles, la profundidad máxima de los árboles, y el tamaño mínimo de los nodos hoja, que permiten controlar su complejidad y mejorar la generalización.

### 3.3. Parámetros del modelo

Es fundamental comprender y analizar los distintos parámetros que definen el comportamiento de cada modelo, ya que estos influyen directamente en su capacidad de ajuste, generalización y rendimiento. Más adelante, se llevarán a cabo pruebas variando estas configuraciones para observar su impacto en los resultados. Esto permitirá explorar cómo los modelos responden a diferentes escenarios y ayudará a identificar la combinación óptima de parámetros para maximizar su desempeño en la tarea de predicción del jugador candidato a ganar el MVP de la NBA. La selección adecuada de estos valores no solo mejorará la precisión de las predicciones, sino que también optimizará el uso de recursos computacionales.

## 4. Resultados y discusión

### 4.1. Que buscamos predecir

Mirando la tabla ”2023-24 NBA Awards Voting”que se encuentra en [2] podemos observar la columna share. Esta columna representa la proporción de puntos obtenidos por un jugador en relación al máximo de puntos posibles en el proceso de votación. Matemáticamente, se define como:

$$\text{Share} = \frac{\text{Pts Won}}{\text{Pts Max}}$$

Donde:

- **Pts Won:** Es la suma total de puntos que un jugador ha recibido durante la votación, considerando el sistema ponderado (los votos por el primer lugar tienen un mayor peso que los de posiciones inferiores).
- **Pts Max:** Representa el máximo número de puntos posibles que un jugador podría haber obtenido si hubiera recibido el voto de primer lugar de todos los participantes.

### 4.2. Interpretación

El valor de *Share* proporciona una medida relativa del desempeño del jugador en la votación, permitiendo evaluar qué tan cerca estuvo de lograr una votación perfecta. Este indicador facilita comparaciones directas entre los jugadores, independientemente de la cantidad de votantes o del total de puntos posibles.

### 4.3. Métricas de evaluación implementadas

Para evaluar el desempeño de los modelos en la predicción del jugador candidato a ganar el MVP de la NBA, se implementó la siguiente métrica:

1. **Precisión en la predicción del ganador del MVP:** Esta métrica analiza si el modelo fue capaz de identificar correctamente al jugador que ganó el premio al Jugador Más Valioso (MVP) de la temporada. Se trata de una evaluación simple que indica si el primer jugador predicho por el modelo coincide con el verdadero ganador del MVP.

### 4.4. Figuras

Primero se probó con un perceptrón multicapa, con 50 neuronas en la capa oculta y una función de activación sigmoide.

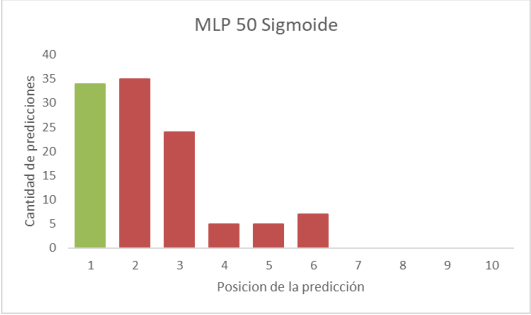



Figura 1: Test Perceptron Multicapa 50 - Sigmoide

Luego se cambió la función de activación a la default del SKLearn, que es la función de activación ReLu. Donde pudimos ver una mejora significativa pero seguía apareciendo el MVP en el 6to lugar.

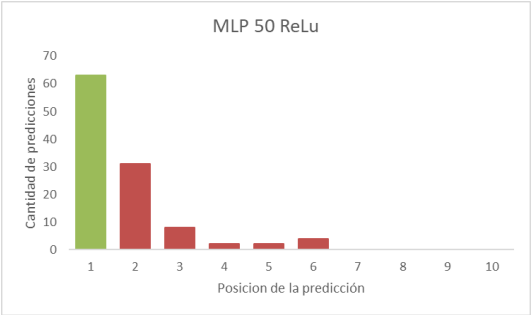



Figura 2: Test Perceptron Multicapa 50 - ReLu

Se aumentaron las capas ocultas a 2, con 50 neuronas y 10 neuronas respectivamente.

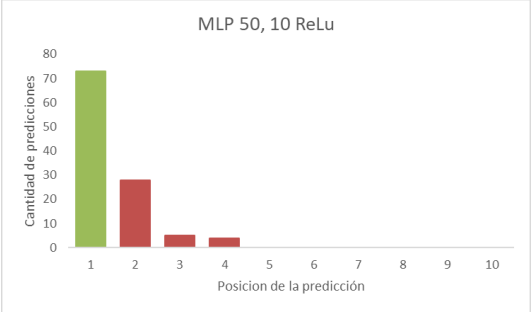



Figura 3: Test Perceptron Multicapa [50,10] - ReLu

Como se seguían observando valores no tan positivos, se opto por probar el siguiente modelo Random Forest. Se testeo con 100 árboles y una máxima profundidad de 20.

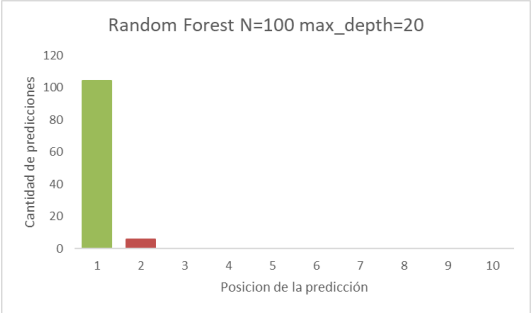



Figura 4: Random Forest - [100,20]

El cambio fue muy significativo positivamente, donde acertó 104 veces al ganador del MVP del correspondiente año y solamente fallo en 6 oportunidades, en esos 6 fallos se lo coloco en el segundo puesto.

Se realizó una prueba mas para el random forest con una cantidad de 100 arboles y una máxima profundidad de 10.

Donde el resultado fue muy similar al testeo anterior, donde esta vez coloco correctamente al MVP 102 veces y lo coloco en el segundo puesto 8 veces. Por lo tanto el mejor modelo seleccionado es el Random Forest con una cantidad de 100 arboles y un máximo de profundidad de 20.

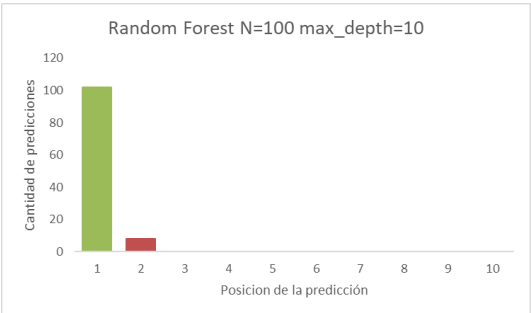



Figura 5: Random Forest - [100,10]

## 5. Conclusiones

El desarrollo del modelo predictor para determinar el ganador del premio MVP de la NBA demostró la efectividad de aplicar técnicas de inteligencia computacional en problemas complejos con grandes volúmenes de datos. En el análisis, el modelo Random Forest superó al perceptrón multicapa en precisión y consistencia, consolidándose como la opción más adecuada para este caso.

El enfoque permitió integrar estadísticas individuales y colectivas de los jugadores, utilizando normalización y selección de características para garantizar una representación adecuada de los datos históricos. Esto facilitó la creación de un modelo robusto capaz de generalizar sobre patrones presentes en décadas de información.

Además, la metodología empleada sienta las bases para futuras aplicaciones en predicciones deportivas. Este trabajo no solo refuerza el valor del análisis estadístico en el ámbito deportivo, sino que también destaca la importancia de elegir modelos adecuados a las características del problema y los datos disponibles. La experiencia obtenida podría extenderse a estudios relacionados, como la predicción de otros premios o el análisis de rendimiento de equipos y jugadores.

## Referencias


[1] Basketball Reference. asketball stats and history statistics, scores, and history for the nba, aba, wnba, and top european competition, . Recuperado de `https://www.basketball-reference.com/`.

[2] Basketball Reference. asketball stats and history statistics, scores, and history for the nba, aba, wnba, and top european competition, . Recuperado de `https://www.basketball-reference.com/awards/awards_2024.html`.