


Medidas de Calidad en Segmentación



De la teoría de conjuntos a la implementación en código


Procesamiento Digital de Imágenes - FICH (UNL)



La anatomía del error en cada píxel

Para evaluar una predicción, debemos clasificar cada píxel comparando nuestra solución contra el Ground Truth (Solución ideal).



	Verde Neón (Verdadero Positivo - TP): Acierto. El modelo y el médico coinciden.
	Rojo (Falso Positivo - FP): Falsa Alarma. El modelo alucina una estructura que no existe.
	Azul Cian (Falso Negativo - FN): Olvido. El modelo ignora una estructura real.
	Gris Oscuro (Verdadero Negativo - TN): Fondo correcto.


El espejismo de la Tasa de Acierto en datos médicos

En imágenes médicas, las regiones de interés suelen ser minúsculas en comparación con el fondo. Esto crea un desbalance masivo que inutiliza el Accuracy.

Un modelo que simplemente predice "todo es fondo" puede obtener un 99% de acierto, siendo clínicamente inútil.

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{FN} + \text{TP} + \text{FP} + \text{TN}}$$

(Tasa de acierto sobre el total de los píxeles)



Problema crítico: Requiere datos estrictamente balanceados.


La lente de área: Evaluando el solapamiento

Para ignorar el engañoso fondo (TN), nos concentramos exclusivamente en la intersección de nuestras predicciones con la realidad usando métricas basadas en datos binarios.

Coeficiente Dice (F1-Score)

$$\text{Dice} = \frac{2 * |\text{Solución} \cap \text{Predicción}|}{(|\text{Solución}| + |\text{Predicción}|)}$$


$$\text{Dice} = \frac{2 * \text{TP}}{(\text{FN} + 2\text{TP} + \text{FP})}$$



Coeficiente Jaccard (IoU - Intersection over Union)

$$\text{Jaccard} = \frac{|\text{Solución} \cap \text{Predicción}|}{|\text{Solución} \cup \text{Predicción}|}$$


$$\text{Jaccard} = \frac{\text{TP}}{(\text{FN} + \text{TP} + \text{FP})}$$



Jaccard penaliza los errores con mayor severidad que Dice

Ambos coeficientes están positivamente correlacionados, pero no se comportan igual ante el error. En términos cuantitativos, Jaccard es un juez mucho más estricto frente a las malas clasificaciones.

$$\text{Jaccard} = \frac{\text{Dice}}{(2 - \text{Dice})}$$



Dice es compasivo; Jaccard es estricto.

Cuando el volumen engaña a las métricas de área

Dos segmentaciones pueden tener exactamente el mismo coeficiente de Dice o Jaccard, pero ser cualitativamente distintas. Las métricas de área son ciegas a la rugosidad, las formas aserradas o los contornos irregulares.




La lente de borde: Midiendo la distancia entre contornos

Evaluamos la separación física entre los límites de la predicción y la solución ideal.


Distancia Media entre Contornos

El error promedio general a lo largo del perímetro.






Distancia de Hausdorff

El “peor error posible” (máxima distancia).
Muy sensible a outliers o píxeles ruidosos.



El impacto clínico de la función de pérdida

Las métricas no solo evalúan; entrenan. Usar métricas de solapamiento (IoU/Dice) durante el entrenamiento altera radicalmente el comportamiento de las Redes Neuronales Convolucionales (CNNs).




IoU impulsa predicciones de alta confianza y bordes afilados, lo que puede llevar a falsos negativos claros. La entropía cruzada a menudo produce mapas de probabilidad más suaves y conservadores, útiles para la revisión clínica.

El reto multiclase en la anatomía real





La mayoría de los problemas médicos reales no son binarios. Debemos segmentar múltiples estructuras adyacentes simultáneamente, como los pulmones y el corazón en una radiografía de tórax.

¿Cómo evaluamos matemáticamente esta complejidad?



La regla de oro: Binarizar cada clase ($c \in C$)

Para evaluar segmentación multiclase, deconstruimos el problema original en múltiples problemas binarios independientes (One-vs-Rest). Se calcula la métrica para cada clase c y luego se promedia el rendimiento.



$\text{PredicciónBinarizada}(x) = 1$ (si $\text{Predicción}(x) == c$)
 $\text{PredicciónBinarizada}(x) = 0$ (si $\text{Predicción}(x) \neq c$)

Matriz de Decisión Diagnóstica

¿Qué métrica utilizar según el objetivo de tu modelo?

Métrica	Tipo	Sensibilidad a Outliers	Caso de Uso Ideal
Accuracy	Píxel global	Muy Baja	Datos perfectamente balanceados (Raro en medicina).
Dice (F1)	Área/Solapamiento	Media	Estándar de la industria, optimización general.
Jaccard (IoU)	Área/Solapamiento	Alta	Penalización estricta de falsos positivos/negativos.
Hausdorff	Distancia/Borde	Máxima	Segmentación de altísima precisión clínica (ej. contornos para radioterapia).

Implementando IoU desde cero con OpenCV

La intersección sobre la unión se reduce matemáticamente a operaciones lógicas a nivel de bits (AND / OR) sobre las matrices de la imagen.



```
# Computo la union y la interseccion
• cv.bitwise_and(gt, pred, intersection)
• cv.bitwise_or(gt, pred, union)

# Computo IoU
iou = cv.sumElems(intersection)[0] / cv.sumElems(union)[0]
```


La vía rápida para entornos médicos: MedPy

Para investigación aplicada, no reinventes la rueda. Librerías especializadas como MedPy implementan las métricas volumétricas y de distancia listas para usar con imágenes tridimensionales.

```
$ pip install medpy
```

asd	Segmentación: métricas de distancia
assd	Segmentación: métricas de distancia
dc (result, reference)	Coeficiente Dice
jc (result, reference)	Coeficiente Jaccard
hd (result, reference)	Distancia de Hausdorff
precision	Precisión
recall	Sensibilidad (Recall)
sensitivity	Sensibilidad
specificity	Especificidad
true_positive_rate	Tasa de verdaderos positivos (TPR)
true_negative_rate	Tasa de verdaderos negativos (TNR)
positive_predictive_value	Valor predictivo positivo (PPV)
ravd	Métricas de segmentación (RAVD)



i Ecosistema actualizado: Explora también MONAI y TorchMetrics para pipelines de Deep Learning modernos y datasets en Grand Challenge.